Laboratorio 8

Diego Bayona, Juan Gonsalez

Universidad de los Andes

Aplicaciones en Ciencia de Datos

Nicolas Suarez Ariza

6 de octubre de 2026

Punto 1

Contar con estas variables por separado permite estructurar la base para hacer filtros y agrupaciones. Con la variable STARS original, responder preguntas como "¿Cuál es la calificación promedio de un director específico?" o "¿En cuántas producciones aparece un actor determinado?" requiere búsquedas de texto complejas y propensas a errores. Al separarlas, se pueden cruzar los datos fácilmente y agrupar estadísticamente a los directores o actores sin que el texto adicional (como "Director:" o "Stars:") ensucie el análisis.

Punto 2

a El patrón es que los caracteres especiales propios de ciertos idiomas (como tildes, letras con diéresis o símbolos de derechos como © o ®) son reemplazados por combinaciones de letras mayúsculas con tildes (como Ã, Â).

b. Esto evidencia un problema de codificación de caracteres (Encoding). Para determinar la etapa, se debe revisar si la herramienta de web scraping extrajo la información en un formato como UTF-8 y si posteriormente el almacenamiento (el CSV o Excel) o la lectura en Python se hizo usando un formato incompatible como ASCII o Latin-1.

Punto 3

La variable que presenta más faltantes es Gross (recaudación) con un 95.9% de valores nulos. Le siguen RunTime con un 31.1% y YEAR con un 6.6%.

Punto 4

Existen 311 registros vacíos en la duración (RunTime).

(a) Eliminar registros nulos: Implica perder el 31% de la base de datos, desperdiciando información útil de otras variables.

(b) Imputar mediante la media (689.58): No es ideal porque la media es muy sensible a valores atípicos (outliers), como series que suman miles de minutos en todas sus temporadas.

(c) Imputar mediante la mediana (600.0): Es el mejor método porque la mediana es una medida robusta frente a los valores extremos, permitiendo rellenar los vacíos sin distorsionar la distribución central real de las duraciones del catálogo. documentales que en total duran 500 minutos. Estos valores extremos arrastrarán la media, haciendo que la imputación no sea realista para la mayoría de películas estándar. (c) Imputar mediante la mediana: Esta es la mejor estrategia. La mediana no se deja afectar por los valores extremos. Representa el "valor del medio" de todas las duraciones. Al usar la mediana para rellenar los vacíos, mantenemos la distribución general de los datos de una forma más conservadora y realista.

Punto 5

Al limpiar la base y quitar las filas exactas, la tabla pasa de 1000 a 888 registros, lo que confirma que hay 112 duplicados. El mejor tratamiento es eliminarlos permanentemente usando una función como drop_duplicates(), ya que mantenerlos genera sesgos estadísticos (inflando la cantidad de votos o la frecuencia de un director/género artificialmente).

Punto 6

El problema es que la columna mezcla texto (paréntesis, guiones), números y celdas con rangos abiertos, lo que la hace inservible para ordenamientos o cálculos temporales. Lo ideal es transformarla extrayendo únicamente los primeros 4 dígitos utilizando expresiones regulares (Regex) para crear una columna numérica llamada "Año de inicio". Para los rangos y los rangos abiertos (ej. 2020-), extraer este primer año permite ubicar temporalmente el debut de la producción en la plataforma de manera estandarizada.

Punto 7

En la base hay 199 registros con RATING igual a 0.00. Este valor no significa que la calidad sea un cero absoluto, sino que son producciones nuevas o poco conocidas que aún no han recibido calificaciones de los usuarios. Si se incluye como un número válido, arrastrará el

promedio general de calificaciones de la plataforma hacia abajo de manera irreal. Debe tratarse y reemplazarse como un valor nulo (NaN) para que las funciones matemáticas lo ignoren.

Punto 8

Confiar en una sola métrica omite la representatividad estadística. Un cortometraje con 5 votos de 10/10 no tiene la misma validación de calidad que una serie como *Breaking Bad* con un 9.5 respaldado por cientos de miles de votos. Para hacer una recomendación útil, propondría crear un Rating Ponderado (multiplicando la calificación por un factor basado en el volumen de votos) o establecer un filtro inicial que exija un umbral mínimo de participación (por ejemplo, excluir del top a cualquier producción que tenga menos de 10,000 votos).

Heading Level 1

Lorem ipsum dolor sit amet, consectetur adipiscing elit. In nec risus pretium, condimentum leo imperdiet, iaculis lacus. Curabitur volutpat sagittis facilisis.

Heading Level 2

Aliquam eget magna pharetra, venenatis metus vel, volutpat nunc. In feugiat ligula quis tellus consectetur malesuada vel et risus.

Heading Level 3

Etiam tempor nisl eu metus facilisis, eget venenatis elit varius. Maecenas nec justo lobortis nulla convallis dapibus commodo ac velit.

Heading Level 4. Vestibulum fringilla eleifend ante, ut cursus eros condimentum. In urna odio, tempus sit amet erat ullamcorper, iaculis condimentum lectus.

Heading Level 5. Phasellus efficitur mi ligula, ac pretium nulla maximus et. Duis imperdiet varius eros eget lacinia. Sed laoreet commodo ex eget vestibulum.

References

Author's last name, Initial(s). (Year of publication). *Title of the book*. Publisher. https://doi.org/DOI

Author's last name, Initial(s). (Year of publication). Title of the article. *Title of Journal*, *Volume*(Issue), Pages. https://doi.org/DOI

Author's last name, Initial(s). (Year, Month Day of publication). *Title of the work*. Website. https://URL

Author's last name, Initial(s). (Year of publication). Title of the article. *Newspaper*. https://URL

Last name, Initial(s). [Channel]. (Year, Month Day of publication). *Title of the video* [Video]. Website. https://URL

Organization. (Year of publication). Word. In *Dictionary*. Publisher. https://URL